Enabling Analytics for Learning Applications with {learnrextra}

Markus Konrad M.Sc. <markus.konrad@htw-berlin.de>, Andre Beinrucker Prof. Dr. <andre.beinrucker@htw-berlin.de>

MultiLA Project / HTW Berlin https://ifafmultila.github.io/

UseR! Conference – July 9, 2024

1. Provide **authoring tool** for interactive learning applications for data science education

- 1. Provide **authoring tool** for interactive learning applications for data science education
 - RStudio with {learnr} and/or {Shiny}

- 1. Provide **authoring tool** for interactive learning applications for data science education
 - RStudio with {learnr} and/or {Shiny}

2. Conveniently set up experiments and collect usage data for learning analytics

- 1. Provide **authoring tool** for interactive learning applications for data science education
 - RStudio with {learnr} and/or {Shiny}

- 2. Conveniently set up experiments and collect usage data for learning analytics
 - **★** Not provided in the R ecosystem so far

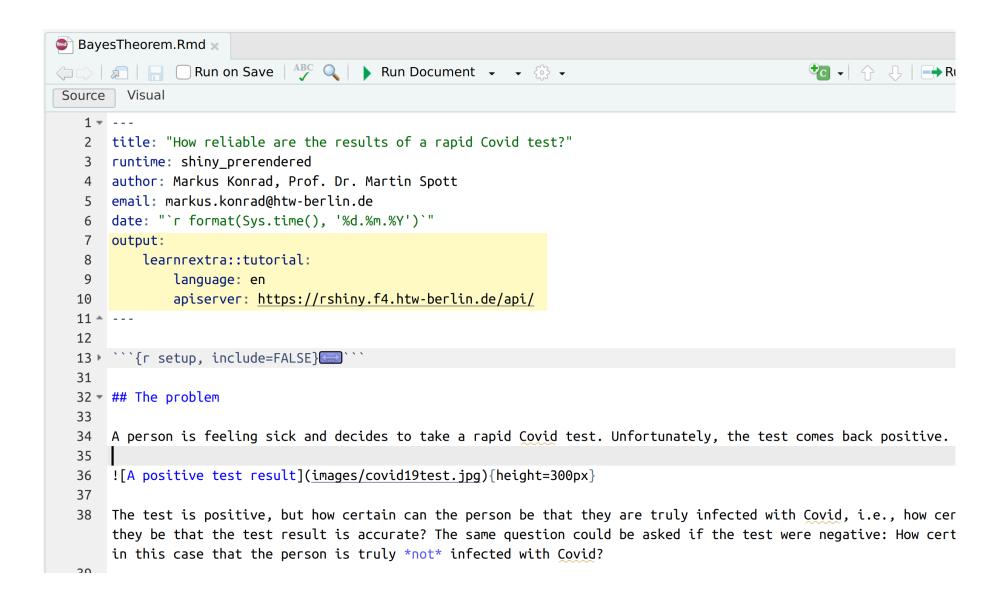
Demonstration of a software system for educational data mining

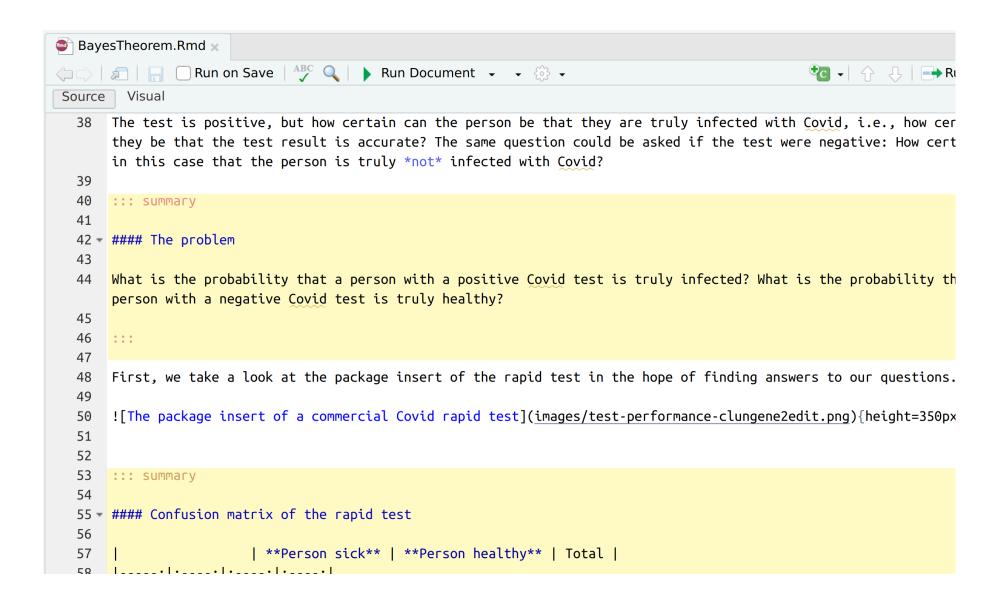
- Demonstration of a software system for educational data mining
- Some technical background

- Demonstration of a software system for educational data mining
- Some technical background
- First observations from in-class experiments

Demonstration

Integrating {learnrextra} in your RMarkdown document

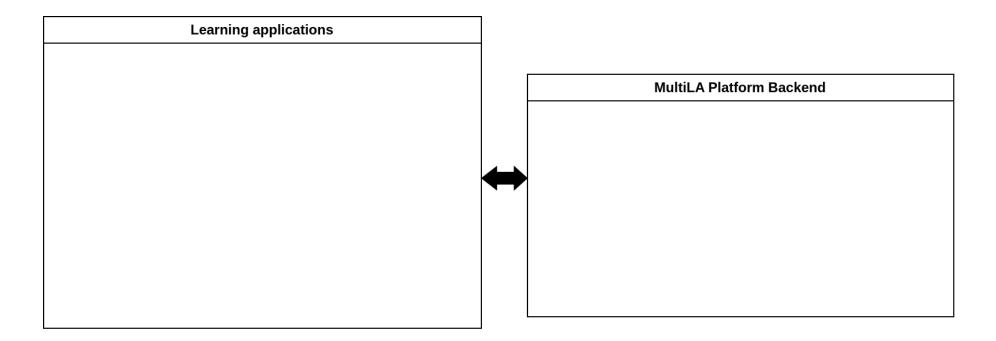


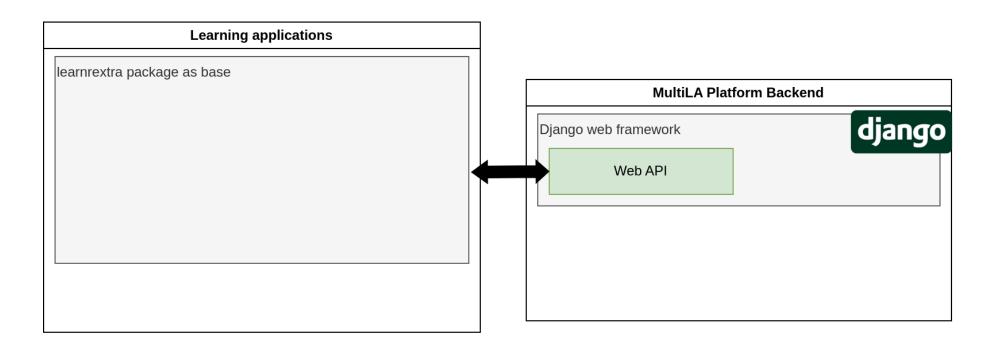


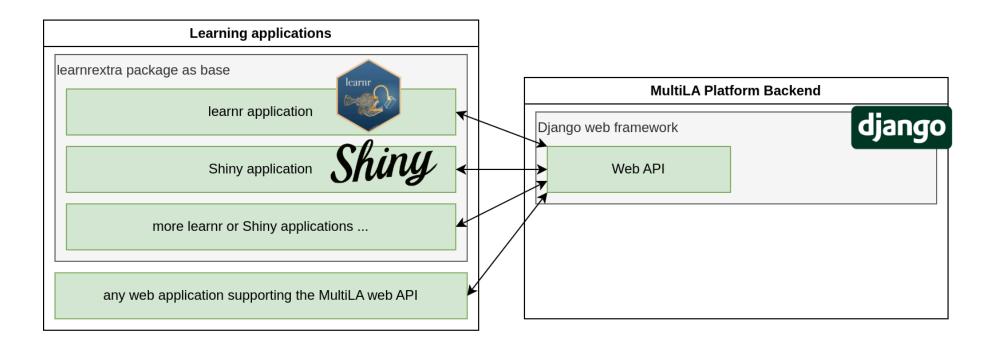
Integrating {learnrextra} in your Shiny app

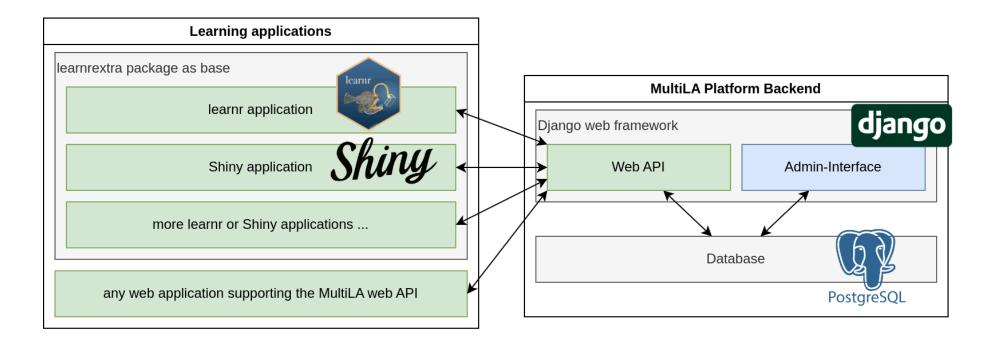
```
app.R ×
▶ Run App →
  1
      #
     # This is an example Shiny web application that uses the learnrextra package to track user interactions.
  3
      #
  4
      library(shiny)
      library(learnrextra)
  7
      options("learnrextra.apiserver" = "https://rshiny.f4.htw-berlin.de/api/")
  9
      # Define UI for application that draws a histogram
 10
      ui <- fluidPage(</pre>
 11
         # set up learnrextra; optionally point to HTML files with tracking consent and data protection notes
 12
         use learnrextra(consentmodal = "www/trackingconsent.html", dataprotectmodal = "www/dataprotect.html"),
 13
 14
 15
         fluidRow(
 16
             column(
                 width = 12,
 17
                 info display()
                                 # show link for data protection and optional login information
 18
 19
 20
         ),
 21
         # Application title
 22
         titlePanel("Old Faithful Geyser Data"),
 23
 24
 25
         # Sidebar with a slider input for number of bins
```

Technical background & software components









First observations from user trials

Learning app for Bayes' theorem

14.05.2024

Markus Konrad, Prof. Dr. Martin Spott

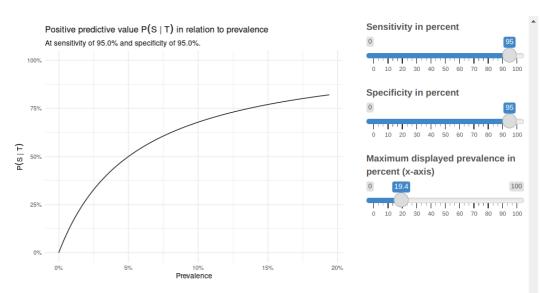
How reliable are the results of a rapid Covid test?

Start Over Data Protection Notice

The problem

Analysis

The influence of prevalence and test accuracy



Why does sensitivity not play such a strong role for the positive predictive value at low prevalence?

- ☐ Because at low prevalence, regardless of the test result, the probability of being sick is very low.
- ☐ Because at low prevalence, the sensitivity is automatically lower.
- \square Because at low prevalence, the term $P(T \mid S)P(S)$ is always very small, so the sensitivity $P(T \mid S)$ can hardly have an influence on the overall result.

Submit Answer

Summary

The problem

What is the probability that a person with a positive Covid test is truly infected? What is the probability that a person with a negative Covid test is truly healthy?

Confusion matrix of the rapid test

		Person sick	Person healthy	Total
	Test positive	139	3	142
	Test negative	13	462	475
	Total	152	465	617

Definition of the events

- S: Person sick and \overline{S} : person healthy,
- T: test positive and \overline{T} : test negative.

Definition of conditional probabilities

 $P(S \mid T)$ – Probability that a person is actually sick, given that the test is positive.

 $P(T\mid S)$ – Probability that a test shows a positive result, given that the person is actually sick (sensitivity).

 $P(\overline{T}\mid \overline{S})$ – Probability that a test shows a negative result, given that the person is actually healthy (specificity).

Bayes' Theorem

$$\begin{split} P(S \mid T) &= \frac{P(T \mid S)P(S)}{P(T)} \\ &= \frac{P(T \mid S)P(S)}{P(T \mid S)P(S) + P(T \mid \overline{S})P(\overline{S})}. \end{split}$$

Discrete probability distributions (German)

06.06.2024 Markus Konrad

Diskrete Wahrscheinlichkeitsverteilungen

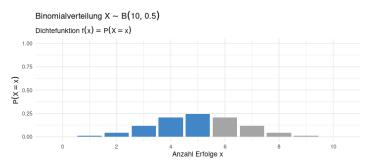
Neustart Datenschutzerklärung

Die Dichtefunktion der Binomialverteilung

Verteilungsfunktion

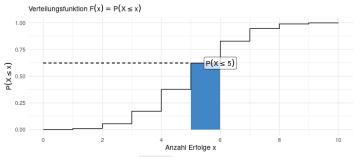
Quantilfunktion

Verteilungsfunktion F(x) gibt uns die Wahrscheinlichkeit dafür, dass X kleiner oder gleich einem Grenzwert x ist, also $F(x) = P(X \le x)$. Zunächst können wir wieder die Dichtefunktion f(x) darstellen und all die Wahrscheinlichkeiten blau hervorheben, die kleiner oder gleich dem Grenzwert x sind. Diese können wir dann aufaddieren und bekommen damit die Verteilungsfunktion F(x). Probieren Sie dafür die folgende interaktive Grafik aus und achten Sie auf das Zusammenspiel zwischen der Dichtefunktion f(x) und der Verteilungsfunktion F(x) darunter:



Für die Verteilungsfunktion F(x) werden die Wahrscheinlichkeiten von allen Werten kleiner oder gleich x aufsummiert. In der Grafik oben sind die Wahrscheinlichkeiten blau gekennzeichnet. Für x=5 bedeutet das also: $F(5)=P(X\le 5)=P(X=0)+P(X=1)+\cdots+P(X=5)=f(0)+f(1)+\cdots+f(5).$

Die Grafik unten stellt nun die Verteilungsfunktion F(x) dar, mit dem Wert für F(5) blau hervorgehoben.



Die Berechnung in R geschieht mit Hilfe von pbinom(). Es werden wieder die Parameter x, n und p übergeben:

> pbinom(5, 10, 0.5) [1] 0.623046875

E



Anzahl Versuche n

0 0.5 1

Anzahl Erfolge \boldsymbol{x} als Grenzwert



Unterer / oberer Bereich



Gleiches Intervall für Y-Achse verwenden

Zusammenfassung

Die Anzahl korrekter Antworten als binomialverteilte Variable

Der Chatbot antwortet üblicherweise in 91% der Fälle korrekt. Ein Experiment mit 35 Versuchen ergibt 29 korrekte Antworten. Die Anzahl der korrekten Antworten lässt sich als Zufallsvariable X auffassen, die binomialverteilt ist mit $X \sim B(35,0.91)$.

Dichtefunktion der Binomialverteilung



$$f(x) = P(X = x) = \binom{n}{x} p^x (1-p)^{n-x}.$$

- Wahrscheinlichkeit, dass X genau den Wert x annimmt
- n Anzahl Versuche
- x Anzahl Erfolge
- ullet p Erfolgswahrscheinlichkeit pro Versuch
- Funktion in R: dbinom(x, n, p)

Verteilungsfunktion der Binomialverteilung



$$F(x) = P(X \le x) = \sum_{k=0}^{x} {n \choose k} p^k (1-p)^{n-k}.$$

- $\ \ \, \hbox{Wahrscheinlichkeit, dass X Werte kleiner oder gleich einem} \\ \ \, \hbox{Grenzwert x annimmt} \\$
- Funktion in R: pbinom(x, n, p)

Continuous probability distributions (German)

^{06.06.2024} Stetige Wahrscheinlichkeitsverteilungen

Neustart Datenschutzerklärung

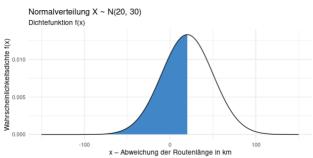
Einführung – stetige Gleichverteilung

Die Normalverteilung

Ouantilfunktion

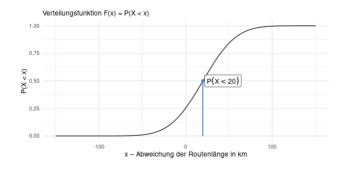
Verteilungsfunktion der Normalverteilung

Wir haben also herausgefunden, dass die Differenz der Routenlängen zum Konkurrenzdienst in etwa normalverteilt ist mit Erwartungswert $\mu=20~\mathrm{km}$ und Standardabweichung $\sigma=30~\mathrm{km}$. Das können wir jetzt nutzen, um die Frage zu beantworten, wie hoch die Wahrscheinlichkeit ist, dass unser Routenberechnungssystem bessere (also kürzere) Routen liefert, als die Konkurrenz. Wir suchen also $P(X<0~\mathrm{km})$. Wie schon bei der stetigen Gleichverteilung können wir bei solchen Fragestellungen auf die Verteilungsfunktion zurückgreifen. Diese gibt uns die Wahrscheinlichkeitsdichte P(X< x) bis zu einem Wert x, also im Intervall $(-\infty,x)$, als Fläche unter der Kurve der Dichtefunktion f(x) der Normalverteilung. Folgende interaktive Grafik zeigt das Prinzip:

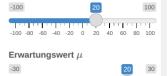


Für die Verteilungstunktion F(x) müssen wir P(X < x) bestimmen. Das entspricht der blau gekennzeichneten Fläche unter der Kurve der Dichtefunktion f(x). Das passiert über das Integral der Dichtefunktion der Normalverteilung, was wir hier nicht weiter vertiefen können.

Die Grafik unten stellt nun die Verteilungsfunktion F(x) dar, mit dem Wert für F(20)=0.50 blau hervorgehoben.



Routenlänge x als Grenzwert



-30 -24 -18 -12 -6 0 6 12 18 24 30

Standardabweichung σ

Unterer / oberer Bereich

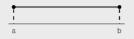
P(X < x)

Zusammenfassung

Besonderheiten bei stetigen Verteilungen

Es gilt
$$P(X=x)=0$$
 und damit $P(X \le x)=P(X < x)$, sowie $P(X \ge x)=P(X > x)$.

Dichtefunktion der stetigen Gleichverteilung



$$f(x) = \left\{ egin{array}{ll} rac{1}{b-a} & ext{falls } a \leq x \leq 0 \ 0 & ext{sonst.} \end{array}
ight.$$

- stetige Gleichverteilung im Intervall [a,b], wobei a < b
- Funktion in R: dunif(x, a, b)

Verteilungsfunktion der stetigen Gleichverteilung



$$F(x) = \begin{cases} 0 & \text{falls } x < a \\ \frac{x-a}{b-a} & \text{falls } a \le x \le b, \\ 1 & \text{falls } x > b \end{cases}$$

- liefert Wahrscheinlichkeit P(X < x) für gleichverteilte Zufallsvariable X
- Funktion in R: punif(x, a, b)

Dichtefunktion der Normalverteilung



• Funktion in R: pnorm(x, mu, sigma)

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

Gave us many insights, including:

Time taken for chapters and tasks

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

- Time taken for chapters and tasks
- Identify tasks that were too tough or too easy

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

- Time taken for chapters and tasks
- Identify tasks that were too tough or too easy
- Issues with code exercises

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

- Time taken for chapters and tasks
- Identify tasks that were too tough or too easy
- Issues with code exercises
- UI issues (much scrolling → summary panel)

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

- Time taken for chapters and tasks
- Identify tasks that were too tough or too easy
- Issues with code exercises
- UI issues (much scrolling → summary panel)
- Overall high satisfaction with the apps

- Small survey (used {learnr} questions for that)
- 29 students participated in statistics class
- Analysis still work-in-progress (see https://github.com/IFAFMultiLA/TrackingDataScripts)

- Time taken for chapters and tasks
- Identify tasks that were too tough or too easy
- Issues with code exercises
- UI issues (much scrolling → summary panel)
- Overall high satisfaction with the apps
- → Directly helped to improve the apps

Summary and outlook

Create in learning apps / tutorials with {learnr},
 {Shiny} or Python

- Create in learning apps / tutorials with {learnr},
 {Shiny} or Python
- Define variants of an app via configurations

- Create in learning apps / tutorials with {learnr},
 {Shiny} or Python
- Define variants of an app via configurations
- Monitor & collect user interactions, survey and feedback data for learning analytics

- Create in learning apps / tutorials with {learnr},
 {Shiny} or Python
- Define variants of an app via configurations
- Monitor & collect user interactions, survey and feedback data for learning analytics
- User tracking is highly granular, configurable and anonymous

- Create in learning apps / tutorials with {learnr},
 {Shiny} or Python
- Define variants of an app via configurations
- Monitor & collect user interactions, survey and feedback data for learning analytics
- User tracking is highly granular, configurable and anonymous
- Prepare raw data for data analysis

- Create in learning apps / tutorials with {learnr},
 {Shiny} or Python
- Define variants of an app via configurations
- Monitor & collect user interactions, survey and feedback data for learning analytics
- User tracking is highly granular, configurable and anonymous
- Prepare raw data for data analysis

Plus: employ A/B testing, use a dynamic summary panel, etc.

 User tracking across different devices is a challenge (simple login supported)

- User tracking across different devices is a challenge (simple login supported)
- Deployment requires server administration skills

- User tracking across different devices is a challenge (simple login supported)
- Deployment requires server administration skills
- Installation is a bit complicated

- User tracking across different devices is a challenge (simple login supported)
- Deployment requires server administration skills
- Installation is a bit complicated
- Small number of participants in own trials so far

Thank you!



https://ifafmultila.github.io/

markus.konrad@htw-berlin.de



University of Applied Sciences





Wirtschaft und Recht Berlin

Berlin School of Economics and Law

